



INSTITUTO POLITECNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

Ingeniería en Inteligencia Artificial

MATERIA:

“Aplicaciones de Lenguaje Natural”

ACTIVIDAD:

**“Sistema Inteligente de Detección de Anomalías mediante
Selección Negativa y Computación Paralela ”**

PRESENTA:

Dimas Gonzalez Santiago

Marcelino López Jessica

GRUPO:

6BM1

INSTITUTO POLITECNICO NACIONAL



Profesor de Materia:

HORACIO ALBERTO GARCIA SALAS

Índice General

Capítulo 1: Introducción	3
1.1 Estado Actual	3
1.2 Estado Ideal	3
1.3 Propuesta de proyecto	3
 Capítulo 2: Investigación previa	 3
2.1 El algoritmo de Selección Negativa	3
1.3.1 Perfilamiento del Tráfico: Normal vs. Anómalo	4
2.2 ¿Qué es un sistema inteligente?	4
2.1.1. Percepción	4
2.1.2. Representación del conocimiento	4
2.1.3. Aprendizaje	5
2.1.4. Acción	5
2.3 Encapsulamiento de Datos	5
 Capítulo 3: Metodología y Evaluación	 5
3.1 Aprendizaje	5
3.2 Acción	5

Capítulo 1: Introducción

1.1 Estado Actual

En la actualidad, la detección de intrusiones en el tráfico de red (NIDS) depende en gran medida de modelos prefabricados o reglas estáticas. Estos enfoques tradicionales pueden ser lentos y, a menudo, fallan al momento de identificar amenazas nuevas que no están registradas en sus bases de datos.

Además, el análisis secuencial de millones de datos puede presentar un tiempo de procesamiento muy lento.

1.2 Estado Ideal

El ecosistema ideal requiere un sistema que no dependa de firmas rígidas, sino que tenga la capacidad de aprender de forma autónoma cómo se ve la normalidad. En este escenario, el sistema debe ser capaz de procesar información de manera simultánea para evaluar millones de posibilidades en tiempo real, minimizando los tiempos de respuesta y maximizando la seguridad.

1.3 Propuesta de proyecto

La presente propuesta consiste en el diseño y desarrollo desde cero de un sistema de detección de anomalías implementado en lenguaje C. La fortaleza de este proyecto radica en la combinación de cuatro áreas clave: IA bioinspirada, ciberseguridad, programación de bajo nivel y computación paralela. A diferencia de usar modelos comerciales ya hechos, construimos el núcleo del algoritmo.

Esto le otorga una gran versatilidad; si en el futuro se desea salir del sector de ciberseguridad, basta con cambiar los datos de entrada para aplicar el mismo sistema a sensores industriales, transacciones financieras o secuencias biológicas.

Capítulo 2: Investigación previa

2.1 El algoritmo de Selección Negativa

El proyecto estará inspirado directamente en el sistema inmunológico humano. En donde nuestro cuerpo tiene 2 tipos de células, las cuales aprenderán a reconocer lo que es del propio organismo (*Self*) y atacan automáticamente a cualquier agente externo que no pertenece a él (*Non-Self*).

Para diseñarlo en un sistema, debemos tener claro el siguiente funcionamiento:

1. *Aprendizaje*

- a. El sistema analiza un conjunto de datos y aprende como es el tráfico normal de la red

2. *Generación*

- a. Se crean miles de “*Detectores*” (Que son equivalentes a los anticuerpos) que representan perfiles de comportamiento anormales.

3. *Evaluación*

- a. ¿Se parece o se relaciona al tráfico normal? -> El tráfico no se bloquea ni genera sospechas.
- b. ¿Es suficientemente diferente y activa los detectores? -> Se clasifica como anomalía y alerta a los administradores

1.3.1 Perfilamiento del Tráfico: Normal vs. Anómalo

Para que los detectores generados por el algoritmo funcione correctamente, el sistema primero debe de entender la diferencia entre el tráfico cotidiano y el sospechoso.

- Tráfico Normal (*Self*)
 - Es el comportamiento esperado o rutinario y seguro dentro de la red; como lo pueden ser los empleados que entran usando sus credenciales, envían correos, descargan archivos o navegan por internet.
- Tráfico Sospechoso (*Non-Self*)
 - Es cualquier patrón o evento que llegue a romper drásticamente con la rutina establecida; como lo puede ser una persona desconocida intentando entrar a la fuerza en horarios no concurridos o intentos de acceso por personas no reconocidas.
 - **Saturación repentina:** Miles de peticiones de información enviadas en milisegundos con la intención de colapsar el sistema.
 - **Exploración sospechosa:** Como se mencionó previamente, puede ser un escaneo silencioso buscando puertos abiertos o sin seguridad e incluso vulnerabilidades en la red.
 - **Fuerza bruta:** Intentos repetidos y masivos para adivinar contraseñas o forzar el acceso a un servidor.

El algoritmo de selección negativa tiene una gran ventaja, y es que el sistema no necesita conocer previamente las técnicas del atacante. Basta con reconocer que el comportamiento de tráfico actual no coincide con la rutina habitual de la red.

2.2 ¿Qué es un sistema inteligente?

Un sistema inteligente es una entidad capaz de percibir su entorno, procesar la información y tomar decisiones que garanticen alcanzar su objetivo. Para este caso, utilizamos algoritmos bio-inspirados que optimizan una solución. Nuestro sistema cumple con las siguientes características

2.1.1. Percepción

Capacidad que tiene el sistema para percibir el entorno y recibir datos; lo cual es útil para nuestro proyecto ya que el entorno es la red de las computadoras.

Debido a que no se implementaran sensores físicos, el sistema recibe los paquetes de información, de los cuales leerá en tiempo real sus características esenciales, tamaños de dato enviado, duración de conexión o número de peticiones por segundo.

Esta percepción consiste en traducir todo ese flujo constante de comunicaciones en un formato numérico que el algoritmo pueda analizar para saber qué está ocurriendo en la red durante todo momento.

2.1.2. Representación del conocimiento

Los sistemas tradicionales de seguridad representan su conocimiento como un diccionario gigante de virus conocidos; si un archivo no está en el diccionario, asumen que es seguro. Nuestro sistema representa el conocimiento de una manera mucho más abstracta e inteligente. Crea un "mapa" o espacio matemático del comportamiento de la red. Lo que es cotidiano y seguro (*Self*) ocupa una zona definida en este mapa. El sistema estructura todo su conocimiento llenando los espacios vacíos de ese mapa con los "detectores". Así, su modelo del mundo no es una lista de ataques, sino una frontera claramente definida entre "lo que somos" y "lo que no somos".

2.1.3. Aprendizaje

El aprendizaje no consiste en memorizar, sino en descartar errores. Durante su fase de entrenamiento, el sistema genera aleatoriamente miles de detectores. Luego, los expone al tráfico normal de la red. Si un detector reacciona ante un comportamiento inofensivo, el sistema "aprende" que ese detector provocaría falsas alarmas y lo elimina inmediatamente. Solo sobreviven aquellos detectores que permanecen en silencio ante lo normal. De esta forma, el sistema madura y afina su precisión de manera autónoma, sin necesidad de que un humano le diga qué debe buscar.

2.1.4. Acción

Finalmente, la inteligencia no está completa si no se tiene la capacidad de influir en el entorno para alcanzar el objetivo. La acción de nuestro sistema se desencadena en el instante en que el tráfico nuevo coincide con la firma de alguno de los detectores sobrevivientes. Al clasificar un paquete de datos como anómalo (*Non-Self*), el sistema abandona su estado pasivo de observación y toma decisiones en fracciones de segundo. La acción puede ir desde generar un registro detallado y emitir una alerta temprana para los administradores de ciberseguridad, hasta actuar de forma preventiva etiquetando o bloqueando dicho tráfico, protegiendo así la integridad de la red antes de que se produzca una vulneración real.

2.3 Encapsulamiento de Datos

El encapsulamiento es el mecanismo en el cual los datos originales generados por una aplicación se “envuelven” de manera secuencial con múltiples capas de información de control (llamadas cabeceras o headers) antes de ser transmitidos por el medio físico. Este proceso se divide en las siguientes capas:

- **Capa de Aplicación:** Contiene el mensaje o datos generados por el usuario o servicio.
- **Capa de Transporte:** Los datos se segmentan y se les añade una cabecera que incluye los puertos de origen y destino, definiendo el protocolo de comunicación y permitiendo identificar qué servicio específico está enviando o recibiendo la información.
- **Capa de Red:** Con la capa anterior, se encapsula en un paquete IP, al cual se le adjuntan las direcciones de origen y destino, estableciendo la ruta que debe seguir la información a través de distintas redes.
- **Capa de enlace:** El paquete se convierte en un frame, añadiendo las direcciones físicas del hardware de red y secuencias de verificación para el control de integridad de los datos.

Capítulo 3: Metodología y Evaluación

3.1 Aprendizaje

El reto de generar y evaluar miles o millones de detectores es el tiempo de cómputo. Para solucionarlo, implementamos computación paralela utilizando la API OpenMP en C. En lugar de que un solo procesador revise cada detector uno por uno (de forma secuencial), dividimos la carga de trabajo: múltiples núcleos del CPU (CPU 1, CPU 2, CPU 3, CPU 4) evalúan diferentes detectores de manera simultánea.

3.2 Acción

Para garantizar la viabilidad y potencia del proyecto, compararemos la versión secuencial normal contra nuestra versión paralela. Las métricas principales a evaluar serán:

- **Precisión del modelo:** Tasa de éxito al detectar anomalías, midiendo detalladamente los falsos positivos y falsos negativos.
- **Tiempo de ejecución:** Cronometraje de la evaluación masiva de datos.
- **Rendimiento paralelo (*Speedup*):** La ganancia real de velocidad al distribuir el trabajo en varios núcleos.
- **Eficiencia algorítmica:** El impacto en el rendimiento conforme se aumenta la cantidad de detectores en el sistema.